

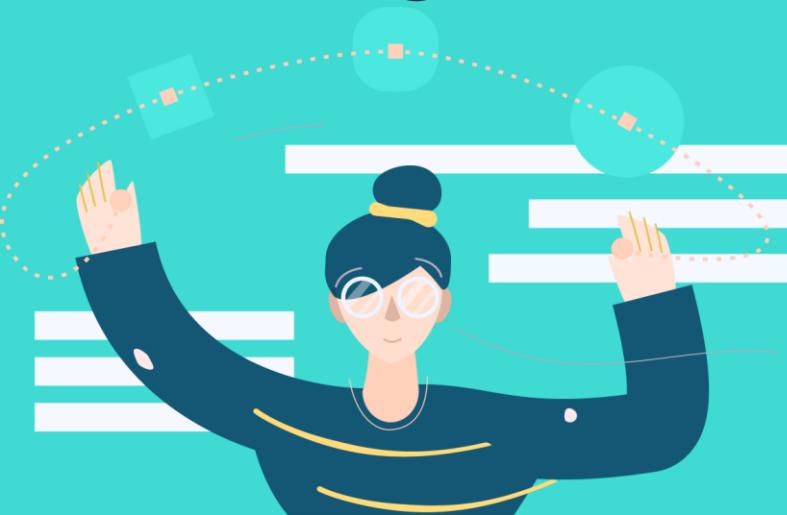


RNCP35288 CDSD

Conversion rate challenge

Supervised Machine Learning

Rédacteur : Jean-Yves Vuillequez





Contexte



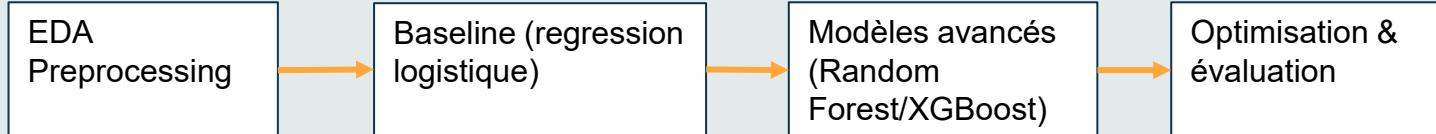
Objectif : prédire le comportement de conversion des visiteurs à partir de leurs données de navigation.



Données à disposition : Caractéristiques utilisateur (âge, nouveau client / existant), comportement de navigation (nombre de pages visitées), acquisition (source de trafic), variable cible



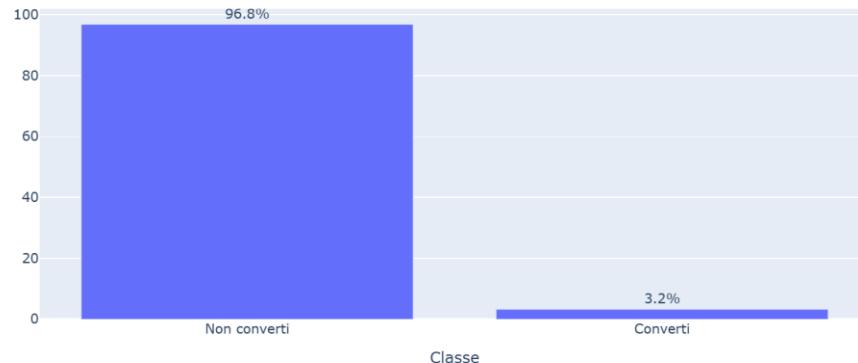
Approche :



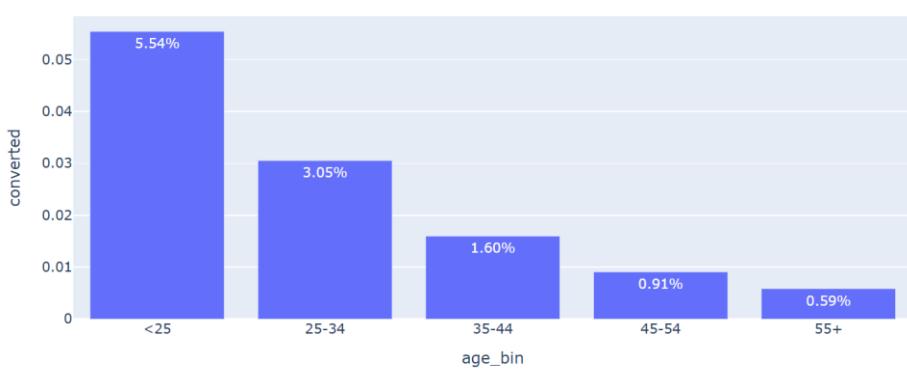


EDA 1/2

Taux de conversion



Conversion par tranche d'âge

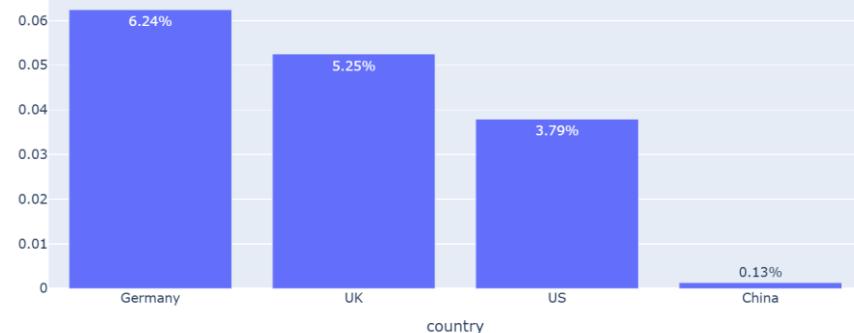


- Le taux de conversion est très déséquilibré : environ 3% de conversions
- Un effet âge très marqué : les plus jeunes convertissent significativement plus que les 45 et plus

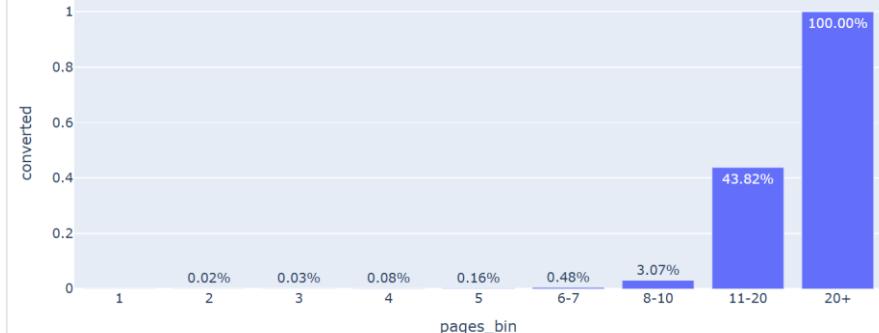


EDA 2/2

Conversion rate par pays



conversion par nombre de pages visitées



- **Un effet pays très marqué :** Les comportements de conversion varient selon le marché avec une sous représentation des conversions en Chine
- **Un effet engagement :** le taux de conversion augmente fortement avec le nombre de pages visitées



Métriques et protocole

Critères d'évaluation du modèle de régression



Métriques choisies :

- **F1-score - Mesure l'équilibre entre faux positifs et faux négatifs** : Indicateur synthétique adapté aux classes déséquilibrées
- **Précision – « Parmi les utilisateurs prédits convertis, combien le sont réellement ? »** : Mesure la fiabilité des prédictions positives et permet de limiter le « gaspillage marketing » (
- **Recall (sensibilité) - « Parmi les vrais convertis, combien sont détectés ? »** : Mesure la capacité du modèle à identifier les opportunités de conversion sans en manquer
- **ROC AUC - « Le modèle sait-il classer correctement les utilisateurs ? »** : Évalue la capacité globale du modèle à distinguer convertis et non-convertis



Résultats

Baseline vs Random Forest / XGBoost

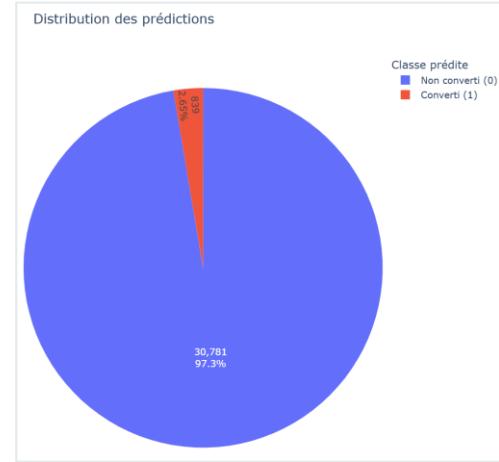
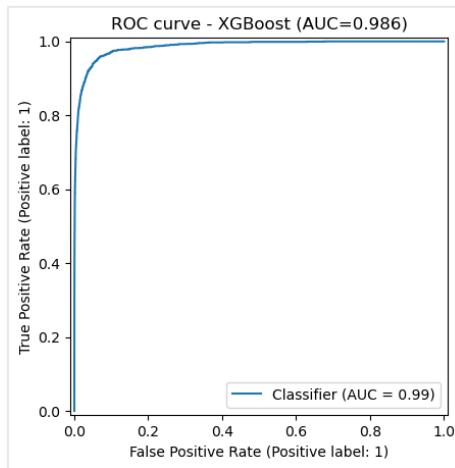
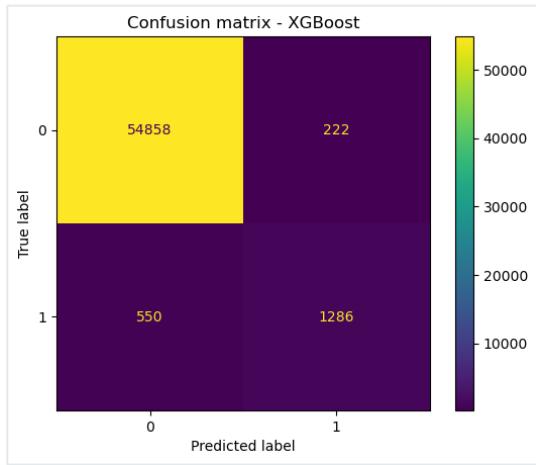
Pipeline : Preprocessing → Feature engineering → Modélisation → Optimisation hyperparamètres

Modèle	F1 score	precision	recall	roc_auc	Diagnostic
LogReg	0.767	0.865	0.690	0.987	Baseline : bonne précision, peu de faux positifs
Random Forest	0.763	0.853	0.691	0.986	Modèle plus complexe sans gain significatif avec la baseline
XGBoost	0.769	0.853	0.700	0.986	Meilleur compromis global : F1 et recall légèrement supérieurs.



Résultats

Analyse XGBoost



- Le modèle détecte efficacement les conversions réelles ($TP = 1\,286$) avec quelques faux positifs ($FP = 222$) mais avec des faux négatifs ($FN = 550$), donc des utilisateurs **convertis**, mais prédits comme non convertis → **Coût métier potentiellement fort** : opportunités manquées
- La distribution des prédictions reste majoritairement « non converti » **en phase avec le faible taux de conversion observé dans les données d'entraînement**



Jedha

Merci pour votre attention
Des questions ?

